RQ3：情景标签与评价证据选择的关联建模

主要规范集与扩展规范集的三层预测、稳健性检验和标签权重

研究语料：125 篇全文论文 · 158 个评价案例 · 490 条候选评价记录 · 600 个测量工具实例

最终整合版本：2026-10-27

1. 研究目标

RQ3 检验：设计师对评价任务所定义的情景标签，能在多大程度上帮助推荐评价维度、主观指标和测量工具。最终输入只保留 G1–G7，不再使用旧模型中的效果主张形式、数据源、评价环境、可行性约束、AI 角色或任务标签。

标签组	代码及类别
G1 评价目的	P1 价值引出与标准建构；P2 模型监督、校准与代理目标；P3 形成性反馈与迭代引导；P4 总结性验证与比较
G2 设计领域	D1 视觉传播；D2 工业 / 产品；D3 时装；D4 室内；D5 服务；D6 UI/UX 设计
G3 设计阶段	S1 研究；S2 构思；S3 原型制作与测试；S4 实施
G4 评价对象	O1 设计成果或解决方案；O2 设计任务或工作流程；O3 AI 辅助设计系统或界面；O4 人的状态或能力；O5 人机协作关系
G5 评价主体	V1 设计任务执行者；V2 设计成果使用者；V3 外部领域专家；V4 一般公众 / 非目标人群；V5 内部研究者 / 系统开发者
G6 目标用户	U1 专业设计从业者；U2 设计学习者 / 新手设计者；U3 非专业创作者
G7 AI 功能	F1 识别需求；F2 知识检索；F3 方案生成；F4 原型实现；F5 评估反馈；F6 迭代优化

G6 只指直接使用 AI 辅助设计 workflow 的人。设计成果的受益者或终端用户不自动进入 G6；只有其实际作出评价判断时才作为 G5 评价主体编码。

2. 分析集与 n 的定义

分析集 / 目标	n	论文数	类别数	n 的含义
主要规范集—评价维度	46	20	4	48 条主要链中，满足类别最小支持阈值的链级观测
主要规范集—主观指标	6	5	1	仅 A1 达到≥5 条且≥3 篇论文；不能多分类建模
主要规范集—测量工具	53	21	4	54 个主要工具实例中满足工具类别支持阈值的实例
扩展规范集—评价维度	155	38	5	链级观测
扩展规范集—主观指标	95	27	10	满足最小支持阈值的链级观测
扩展规范集—测量工具	182	38	5	工具实例级观测

最小支持阈值为：输出类别至少 5 个观测且来自至少 3 篇论文。评价维度和主观指标以证据链为观测单位；工具以测量工具实例为观测单位。

3. 三层建模与验证

1. 第一层：G1–G7 情景标签 → 评价维度。
2. 第二层：情景标签 + 已确定评价维度 → 主观指标。
3. 第三层：情景标签 + 已确定评价维度和主观指标 → 测量工具类别。

比较模型包括频率基线、L2 多项逻辑回归、随机森林和直方图梯度提升，以 Macro-F1 选择最佳非基线模型，并报告 Top-2 准确率。所有交叉验证按 paper_id 分组，避免同一论文中高度相似的任务、样本、题项或工具同时进入训练集和测试集。否则模型可能记住论文风格而不是学习可推广的情景—证据关系，测试分数会虚高。

4. 模型结果

4.1 主要规范集

推荐目标	n	论文数	类别数	最佳模型	Macro-F1	Top-2 准确率
评价维度	46	20	4	随机森林	.313	.858
主观指标	6	5	1	无法建模	—	—
测量工具类别	53	21	4	L2 多项逻辑回归	.286	.716

主要规范集的 48 条链并非只有 6 条有指标：其中 47 条有可映射指标，但分散在 22 类。应用最小支持阈值后，只有 A1 新颖性保留 6 条、5 篇论文，因此无法建立主观指标多分类模型。

4.2 扩展规范集

推荐目标	n	论文数	类别数	最佳模型	Macro-F1	频率基线	Top-2 准确率
评价维度	155	38	5	随机森林	.464	.105	.836
主观指标	95	27	10	随机森林	.523	.013	.808
测量工具类别	182	38	5	直方图梯度提升	.306	.094	.630

三层模型均优于频率基线，但维度和工具模型仍不足以支持自动给出唯一答案。合理输出应是带证据量与不确定性的候选排序。

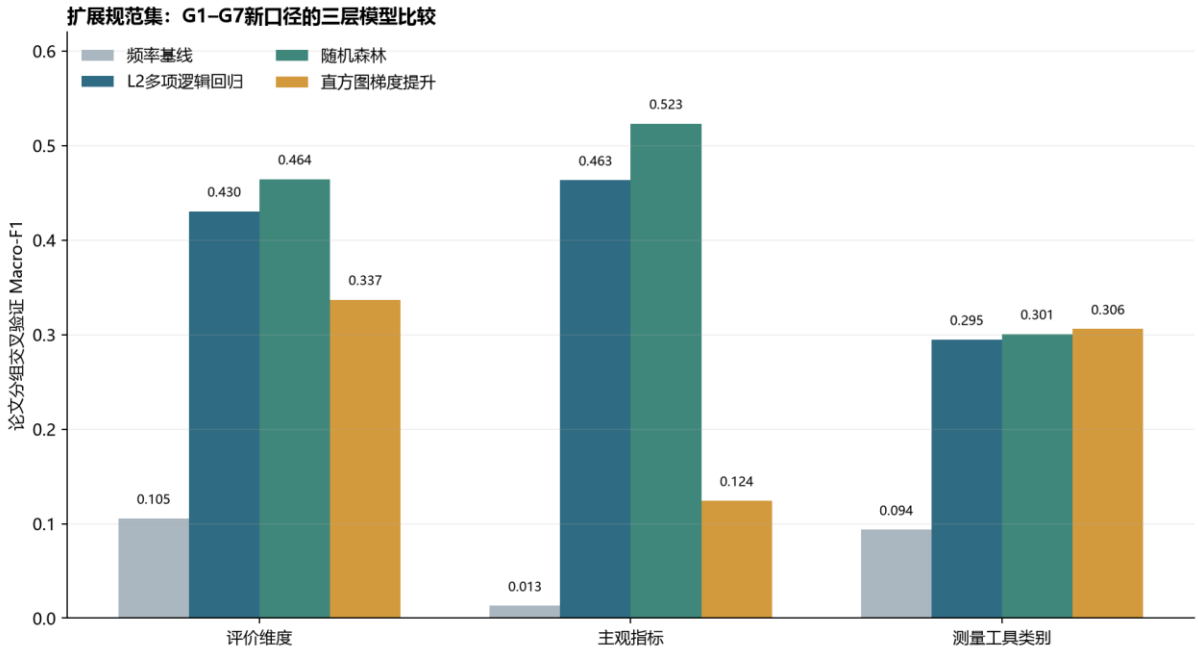


图 1　主要规范集与扩展规范集的候选模型比较

图 1 对应数据表

图中柱高对应 Macro-F1 均值；频率基线及全部候选模型均列出。

分析集	推荐目标	模型	n	论文数	类别数	折数	Macro-F1 均值	标准差	Top-2 准确率
主要规范集	评价维度	频率基线	46	20	4	5	0.130	0.038	—
主要规范集	评价维度	L2 多项逻辑回归	46	20	4	5	0.299	0.067	0.768
主要规范集	评价维度	随机森林	46	20	4	5	0.313	0.189	0.858
主要规范集	评价维度	直方图梯度提升	46	20	4	5	0.130	0.038	0.537
主要规范集	测量工具类别	频率基线	53	21	4	4	0.136	0.029	—
主要规范集	测量工具类别	L2 多项逻辑回归	53	21	4	4	0.286	0.150	0.716
主要规范集	测量工具类别	随机森林	53	21	4	4	0.239	0.193	0.649
主要规范集	测量工具类别	直方图梯度提升	53	21	4	4	0.226	0.148	0.627

分析集	推荐目标	模型	n	论文数	类别数	折数	Macro-F1 均值	标准差	Top-2 准确率
扩展规范集	评价维度	频率基线	155	38	5	5	0.105	0.014	—
扩展规范集	评价维度	L2 多项逻辑回归	155	38	5	5	0.430	0.145	0.740
扩展规范集	评价维度	随机森林	155	38	5	5	0.464	0.162	0.836
扩展规范集	评价维度	直方图梯度提升	155	38	5	5	0.337	0.065	0.675
扩展规范集	主观指标	频率基线	95	27	10	3	0.013	0.007	—
扩展规范集	主观指标	L2 多项逻辑回归	95	27	10	3	0.463	0.044	0.726
扩展规范集	主观指标	随机森林	95	27	10	3	0.523	0.046	0.808
扩展规范集	主观指标	直方图梯度提升	95	27	10	3	0.124	0.064	0.400
扩展规范集	测量工具类别	频率基线	182	38	5	5	0.094	0.012	—
扩展规范集	测量工具类别	L2 多项逻辑回归	182	38	5	5	0.295	0.045	0.641
扩展规范集	测量工具类别	随机森林	182	38	5	5	0.301	0.127	0.638
扩展规范集	测量工具类别	直方图梯度提升	182	38	5	5	0.306	0.108	0.630

5. 标签贡献、稳健性与综合排序权重

每层最佳模型在 20 次不同随机种子的论文级分组交叉验证中复算。标签贡献同时采用两种检验：①删除整个 G 组后重新训练；②在测试集置换整个 G 组。贡献定义为完整模型 Macro-F1 减去受扰动模型 Macro-F1。只有两种方法的 95% bootstrap 置信区间都高于 0，才视为双重稳健。综合排序权重是两种正向平均贡献各自归一化后等权平均，仅用于提问顺序和匹配排序，不代表因果或理论重要性。

推荐目标	综合排序权重	双重稳健标签
评价维度	G4 96.7%；G1 1.9%；G3 1.1%；G7 0.4%；其余 0	G4
主观指标	G1 30.9%；G2 27.7%；G4 14.8%；G7 11.0%；G3 7.9%；G6 7.3%；G5 0.3%	G1、G2

推荐目标	综合排序权重	双重稳健标签
测量工具	G3 22.9%；G7 18.6%；G1 16.8%；G6 15.1%；G2 10.4%；G4 8.6%；G5 7.5%	G1、G2、G3、G6、G7

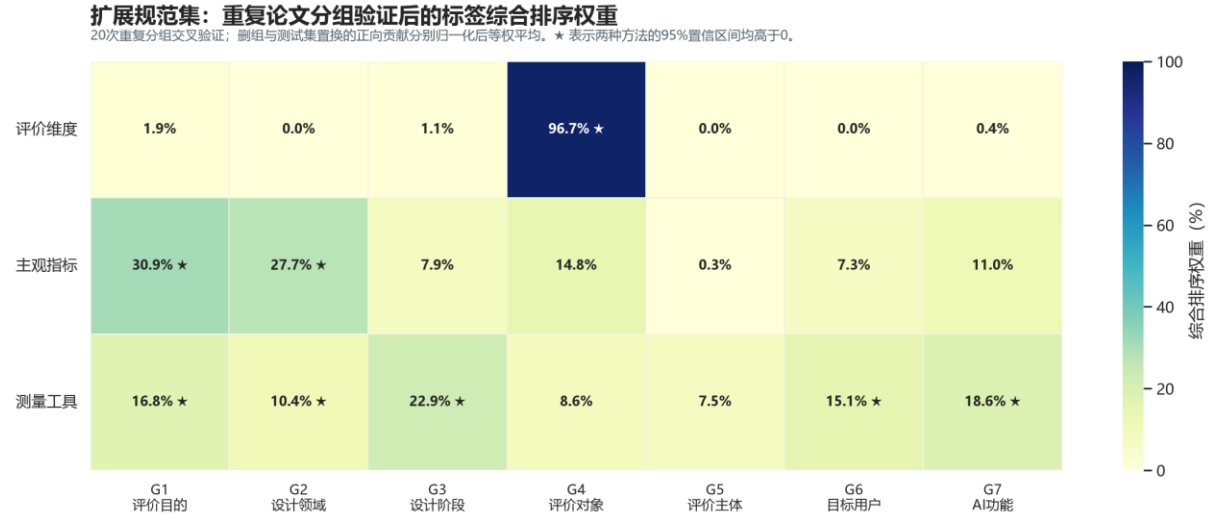


图 2 扩展规范集的标签组综合排序权重

图 2 对应数据表

权重为删组贡献与置换贡献分别正向归一化后等权平均；同一推荐层权重合计 100%。

推荐目标	标签组	综合排序权重	双重稳健	进入核心界面	本层 one-SE 阈值
评价维度	G1_评价目的	1.9%	否	否	96.7%
评价维度	G2_设计领域	0.0%	否	否	96.7%
评价维度	G3_设计阶段	1.1%	否	否	96.7%
评价维度	G4_评价对象	96.7%	是	是	96.7%
评价维度	G5_评价主体	0.0%	否	否	96.7%
评价维度	G6_目标用户	0.0%	否	否	96.7%
评价维度	G7_AI 功能	0.4%	否	否	96.7%
主观指标	G1_评价目的	30.9%	是	是	27.7%
主观指标	G2_设计领域	27.7%	是	是	27.7%
主观指标	G3_设计阶段	7.9%	否	否	27.7%
主观指标	G4_评价对象	14.8%	否	否	27.7%
主观指标	G5_评价主体	0.3%	否	否	27.7%
主观指标	G6_目标用户	7.3%	否	否	27.7%

推荐目标	标签组	综合排序权重	双重稳健	进入核心界面	本层 one-SE 阈值
主观指标	G7_AI 功能	11.0%	否	否	27.7%
测量工具类别	G1_评价目的	16.8%	是	是	15.1%
测量工具类别	G2_设计领域	10.4%	是	否	15.1%
测量工具类别	G3_设计阶段	22.9%	是	是	15.1%
测量工具类别	G4_评价对象	8.6%	否	否	15.1%
测量工具类别	G5_评价主体	7.5%	否	否	15.1%
测量工具类别	G6_目标用户	15.1%	是	是	15.1%
测量工具类别	G7_AI 功能	18.6%	是	是	15.1%

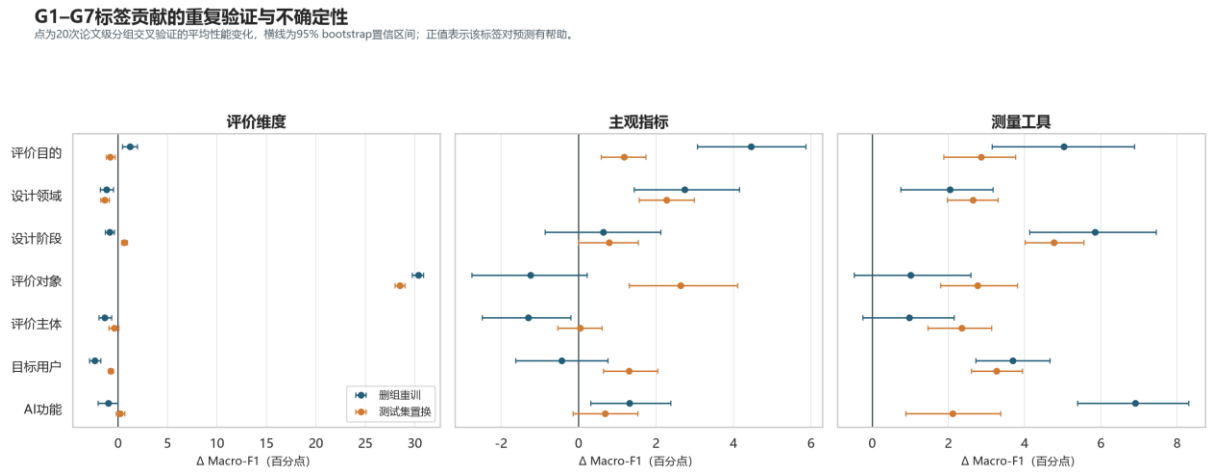


图 3 删除重训与测试集置换的原始 ΔMacro-F1 及 95%区间

图 3 对应数据表

正值表示扰动该标签组后模型性能下降；两种 95%区间均高于 0 才判为双重稳健。

推荐目标	标签组	删组 ΔMacro-F1	删组 95% CI	置换 ΔMacro-F1	置换 95% CI	双重稳健
评价维度	G1_评价目的	0.0121	[0.0044, 0.0194]	-0.0079	[-0.0123, -0.0030]	否
评价维度	G2_设计领域	-0.0115	[-0.0180, -0.0047]	-0.0134	[-0.0176, -0.0087]	否
评价维度	G3_设计阶段	-0.0086	[-0.0130, -0.0037]	0.0062	[0.0034, 0.0094]	否
评价维度	G4_评价对象	0.3037	[0.2973, 0.3089]	0.2850	[0.2800, 0.2900]	是
评价维度	G5_评价主体	-0.0134	[-0.0196, -	-0.0041	[-0.0091, 0.0008]	否

推荐目标	标签组	删组 ΔMacro-F1	删组 95% CI	置换 ΔMacro-F1	置换 95% CI	双重稳健
			0.0067]			
评价维度	G6_目标用户	-0.0236	[-0.0291, -0.0177]	-0.0073	[-0.0096, -0.0047]	否
评价维度	G7_AI 功能	-0.0098	[-0.0203, -0.0002]	0.0021	[-0.0021, 0.0067]	否
主观指标	G1_评价目的	0.0446	[0.0306, 0.0587]	0.0118	[0.0058, 0.0174]	是
主观指标	G2_设计领域	0.0274	[0.0143, 0.0415]	0.0227	[0.0157, 0.0298]	是
主观指标	G3_设计阶段	0.0064	[-0.0087, 0.0212]	0.0079	[-0.0000, 0.0153]	否
主观指标	G4_评价对象	-0.0124	[-0.0276, 0.0022]	0.0263	[0.0131, 0.0410]	否
主观指标	G5_评价主体	-0.0129	[-0.0249, -0.0020]	0.0005	[-0.0054, 0.0060]	否
主观指标	G6_目标用户	-0.0043	[-0.0162, 0.0076]	0.0130	[0.0064, 0.0204]	否
主观指标	G7_AI 功能	0.0132	[0.0031, 0.0238]	0.0068	[-0.0014, 0.0153]	否
测量工具类别	G1_评价目的	0.0503	[0.0314, 0.0689]	0.0286	[0.0188, 0.0376]	是
测量工具类别	G2_设计领域	0.0205	[0.0075, 0.0317]	0.0265	[0.0197, 0.0330]	是
测量工具类别	G3_设计阶段	0.0585	[0.0413, 0.0746]	0.0477	[0.0401, 0.0556]	是
测量工具类别	G4_评价对象	0.0101	[-0.0047, 0.0259]	0.0276	[0.0179, 0.0381]	否
测量工具类别	G5_评价主体	0.0097	[-0.0024, 0.0215]	0.0235	[0.0146, 0.0313]	否
测量工具类别	G6_目标用户	0.0369	[0.0271, 0.0466]	0.0327	[0.0260, 0.0395]	是
测量工具类别	G7_AI 功能	0.0690	[0.0538, 0.0830]	0.0212	[0.0088, 0.0337]	是

5.1 对旧图 100%结果的更正

旧图‘主观指标—G6 目标用户 100%’来自一次交叉验证中把负贡献截为 0 后仅剩一个极小正值（ΔMacro-F1=.019），再做行归一化的数学结果；其 95%区间[-.008,.065]跨 0。重复验证后，G6 删组均值为-.004，结论不稳健。因此撤回 100%解释，主观指标层的稳定信号为 G1 评价目的和 G2 设计领域。

5.2 G4 的语义重叠敏感性

G4 评价对象与评价维度在概念上可能部分重叠。移除 G4 后，主要规范集维度模型 Macro-F1 由.313 降至.200，扩展规范集由.464 降至.207；重复审计的删组贡献约 30.4 个百分点、置换贡献约 28.5 个百分点。G4 是强预测信号，但应解释为用于路由维度的情景标签，不能据此宣称其对 Perceived Effect 具有因果作用。

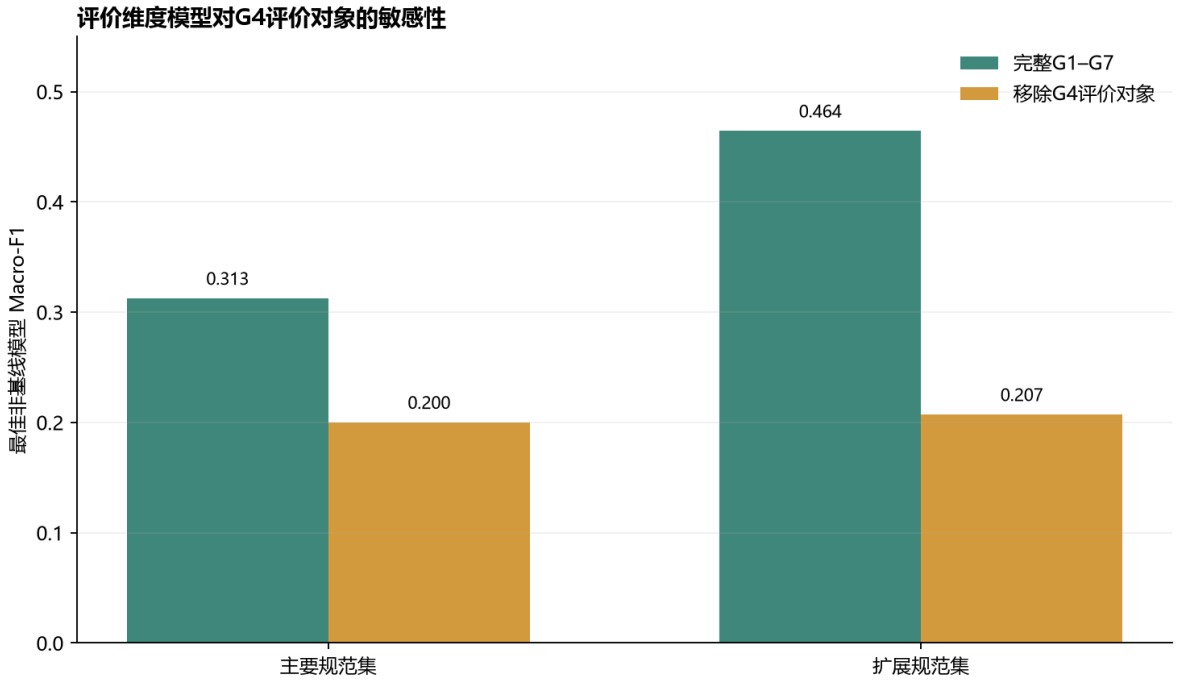


图 4 评价维度模型移除 G4 后的敏感性结果

图 4 对应数据表

柱高为论文分组交叉验证的 Macro-F1 均值。

分析集	最佳模型	完整 G1–G7 Macro-F1	移除 G4 Macro-F1	下降值
主要规范集	随机森林	0.313	0.200	0.113
扩展规范集	随机森林	0.464	0.207	0.257

6. RQ3 结论

- 评价维度主要由评价对象帮助路由；评价目的和设计领域主要帮助细化主观指标。
- 测量工具更依赖实施条件：设计阶段、AI 功能、评价目的和目标用户共同提供稳定信息。
- 主要规范集用于严格验证，但样本过小；扩展规范集用于模型开发和推荐，必须同时显示证据等级。
- 模型输出应为候选排序、支持论文数、工具实例数和可追溯证据，不应伪装为唯一正确选择。